



Propuesta de Trabajo Práctico

Identificación

Asignatura: Ciencia de Datos (Electiva)

Curso: TQ

Objetivos

Presentar de forma clara y viable una propuesta de proyecto siguiendo el ciclo de un proyecto de Data Science: comprensión del problema, definición de la pregunta, identificación y preparación de datos, análisis/modelado, evaluación y comunicación de resultados.

Actividad

Completar el siguiente formulario:

1. Tema del proyecto

Orientación: Indique el tema o área de aplicación. Debe ser específico y estar vinculado con un problema que pueda abordarse mediante datos.

Tema:

Detección y predicción de sobrecostos en obras públicas del Paraguay

Contexto o dominio:

Contrataciones públicas del Paraguay (DNCP)

Breve descripción del problema:

Las contrataciones de obras públicas pueden presentar diferencias entre el monto estimado, el monto adjudicado y el monto finalmente ejecutado o modificado. El proyecto busca analizar estas variaciones, identificar los factores asociados a incrementos significativos del valor



contractual y construir un modelo que permita estimar el riesgo de que una contratación termine con un aumento elevado respecto del monto adjudicado. “SobreCosto” se utilizará como término que determina la medida analítica de incremento contractual y no como evidencia de irregularidad.

2. Pregunta a responder

Orientación: Formule una pregunta principal que el proyecto buscará responder utilizando datos. Debe ser concreta, medible y coherente con los datos que se espera obtener.

Pregunta principal:

¿Cuáles podrían ser los factores o causas que se relacionan con un incremento significativo del valor de una contratación de obra pública respecto del monto adjudicado y qué tan bien se puede predecir, antes de la finalización del proceso, el riesgo de que ocurra dicho incremento?

¿Por qué es importante responderla?

Responder esta pregunta permite comprender qué características de las contrataciones están asociadas a mayores incrementos de valor y evaluar si los datos disponibles permiten anticipar contrataciones de mayor riesgo. Esto puede aportar evidencia para mejorar el análisis y monitoreo de la contratación pública, sin asumir que un incremento implica necesariamente una irregularidad.

3. Objetivo general

Orientación: Redacte un único objetivo general. Debe expresar el resultado principal que se desea alcanzar y comenzar, preferentemente, con un verbo en infinitivo (analizar, predecir, identificar, clasificar, estimar, comparar, etc.).

Objetivo general:

Analizar los factores asociados a los incrementos significativos del valor de las contrataciones de obras públicas en Paraguay y desarrollar un modelo de Machine Learning que permita predecir el riesgo de que una contratación presente dicho incremento.

4. Objetivos específicos



Orientación: Defina entre 3 y 5 objetivos específicos que describan los pasos necesarios para alcanzar el objetivo general. Deben ser observables y verificables.

Objetivo específico 1:

Limpiar los datos de DNCP correspondientes a convocatorias, adjudicaciones, contratos y modificaciones, relacionándolos mediante los identificadores de los procesos y contratos para generar la variable target

Objetivo específico 2:

Feature Engineering: Construir indicadores de variación de valor, especialmente el porcentaje de incremento entre el monto adjudicado y el monto contractual final, y explorar su distribución según características del proceso.

Objetivo específico 3:

Identificar mediante análisis estadístico y exploratorio los factores asociados con mayores incrementos de valor, considerando variables como modalidad, cantidad de oferentes, monto, duración y características del proceso.

Objetivo específico 4 (opcional):

Entrenar y comparar modelos predictivos para estimar la probabilidad de que una contratación supere un umbral de incremento significativo definido a partir de los datos y criterios metodológicos del proyecto.

Objetivo específico 5 (opcional):

Evaluar el desempeño y la interpretabilidad del modelo, identificar variables relevantes y comunicar los principales patrones y casos anómalos encontrados.

5. Datos necesarios



Orientación: Describa qué datos serán necesarios para responder la pregunta y alcanzar los objetivos. En esta etapa no es necesario realizar todavía el análisis.

Fuente(s) de datos:

Dirección Nacional de Contrataciones Públicas (DNCP), Portal de Datos Abiertos:
<https://www.contrataciones.gov.py/datos/data>

Variables o atributos principales:

Identificador del proceso de contratación; identificador del contrato; entidad convocante; modalidad/tipo de procedimiento; objeto y categoría de contratación; fecha de convocatoria y adjudicación; monto estimado; monto adjudicado; monto contractual; modificaciones; monto final o acumulado disponible; cantidad de oferentes; proveedor adjudicado; plazo/duración; estado del proceso; año; lotes e ítems relacionados.

Unidad de análisis:

Una contratación/proceso de obra pública, integrada a partir de sus registros de convocatoria, adjudicación, contrato y modificaciones.

Cantidad aproximada de datos (si se conoce):

No se conoce con precisión aún, pero se espera trabajar con varios cientos de procesos/registros históricos de contratación, dependiendo de los años y filtros seleccionados.

Formato de los datos:

Archivos CSV comprimidos por año y/o datos obtenidos mediante los servicios web de DNCP, con estructura basada en OCDS. Será necesario transformar datos anidados de procesos, lotes e ítems a tablas relacionales para el análisis.

Consideraciones de privacidad, ética o permisos:



Los datos son públicos y no se prevé tratar información personal sensible. El análisis se presentará como estudio estadístico/predictivo: un incremento elevado no se interpretará automáticamente como corrupción, fraude o sobre facturación. Se documentarán las limitaciones, faltantes, posibles sesgos y diferencias entre un indicador analítico de sobre costo y una determinación legal o administrativa.

6. Metodología propuesta de Data Science

Orientación: Explique brevemente cómo se desarrollará el proyecto. Puede utilizar como guía un proceso similar a CRISP-DM, adaptado a la materia.

a) Comprensión del problema:

Delimitar el problema a contrataciones de obras públicas y definir operacionalmente el “incremento significativo” como un aumento del valor contractual final respecto del monto adjudicado, sujeto a disponibilidad de datos de modificaciones.

b) Comprensión y exploración de los datos:

Explorar la calidad, cobertura temporal, la estructura general, los valores faltantes, duplicados y consistencia de los identificadores. Analizar la distribución de montos, número de oferentes e incrementos por año, modalidad y entidad.

c) Limpieza y preparación de los datos:

Desanidar procesos, lotes e ítems; relacionar las tablas por identificadores; normalizar montos y fechas; tratar valores faltantes y duplicados; validar consistencia entre etapas y construir variables derivadas como porcentaje de incremento, cantidad de modificaciones y concentración de proveedores cuando corresponda.

d) Análisis y/o modelado:

Realizar análisis estadísticos para estudiar asociaciones entre el incremento contractual y las variables explicativas. También se buscará correlaciones entre variables.

Para Machine Learning, comparar modelos de clasificación como Regresión Logística, Random Forest y XGBoost para predecir el riesgo de incremento significativo; opcionalmente evaluar regresión para predecir el porcentaje de incremento.



e) Evaluación de resultados:

Separar entrenamiento y prueba, donde se puede hacer una validación cruzada walk-forward orden temporal cuando sea posible para evitar fuga de información o en el caso que no consigamos muchos datos Leave-One-Out Cross-Validation. Evaluar clasificación mediante ROC-AUC, Precision, Recall, F1 y matriz de confusión, si es que hacemos clasificación, en el caso que hagamos regresión podrías usar métricas como RMSE o MAE.

f) Visualización y comunicación de resultados:

Analizar calibración e importancia de variables/SHAP cuando sea viable. Histogramas y boxplots del porcentaje de incremento; evolución temporal; comparaciones por modalidad y entidad; dispersión entre monto adjudicado e incremento; distribución del número de oferentes; ranking de factores relevantes; matriz de confusión y curva ROC; y tablero/resumen de contrataciones con mayor incremento o mayor riesgo predictivo.

7. Técnicas y herramientas previstas

Orientación: Indique las técnicas y herramientas que considera utilizar. Esta selección puede modificarse durante el desarrollo del proyecto.

Técnicas estadísticas / análisis exploratorio:

Estadística descriptiva; percentiles; medidas de tendencia y dispersión; análisis de correlación; comparación de distribuciones entre grupos; análisis temporal; detección de outliers y análisis de concentración de proveedores.

Técnicas de Machine Learning (si corresponde):

Regresión Logística como línea base; Random Forest; XGBoost; para el caso que hagamos regresión lineal, Random Forest Regressor o XGBoost Regressor como alternativas. Por otro lado, se usará selección/regularización de variables cuando corresponda; validación cruzada y análisis de importancia/interpretabilidad.

Herramientas y lenguajes:



Python; Pandas; NumPy; Scikit-learn; XGBoost; Matplotlib/Seaborn para visualización; Jupyter Notebook.

Visualizaciones previstas:

Distribución y percentiles del incremento; evolución temporal; comparación por modalidad y entidad; relación monto-oferta-incremento; ranking de entidades/proveedores; curva ROC; matriz de confusión; importancia de variables y visualizaciones de casos de mayor riesgo.

8. Resultado o producto esperado

Orientación: Describa qué se espera obtener al finalizar el proyecto: hallazgos, modelo predictivo, clasificación, segmentación, dashboard, visualizaciones, recomendaciones u otro producto.

Resultado esperado:

Un dataset analítico integrado de contrataciones de obras públicas; un conjunto de indicadores de incremento contractual; un análisis de los factores asociados a los sobrecostos; y un modelo predictivo que estime el riesgo de incremento significativo, acompañado de métricas de evaluación e interpretación de resultados.

¿Cómo se evaluará si el proyecto respondió la pregunta inicial?

Se considerará respondida cuando: (1) se hayan identificado y cuantificado los principales factores asociados al incremento contractual; (2) el modelo supere una línea base sencilla con métricas adecuadas dependiendo si se hace clasificación o regresión; y (3) se determine con evidencia si las variables disponibles permiten predecir de forma útil el riesgo de un incremento significativo. Las conclusiones incluirán las limitaciones y no se interpretarán como determinaciones legales de irregularidad.

9. Lista de verificación antes de entregar

- ☒ ~~El tema está claramente delimitado.~~
- ☒ ~~Existe una pregunta principal que puede responderse con datos.~~
- ☒ ~~El objetivo general responde directamente a la pregunta.~~
- ☒ ~~Los objetivos específicos conducen al logro del objetivo general.~~
- ☒ ~~Se identificaron fuentes de datos realistas y accesibles.~~
- ☒ ~~La metodología incluye preparación, análisis/modelado y evaluación.~~
- ☒ ~~Se consideraron aspectos éticos, de privacidad y calidad de los datos.~~
- ☒ ~~El resultado esperado permite verificar si se respondió la pregunta.~~



10. Referencias / fuentes iniciales

Incluya enlaces, artículos, datasets, documentación técnica u otras fuentes utilizadas para formular la propuesta.

1. DNCP – Portal de Datos Abiertos. <https://www.contrataciones.gov.py/datos/data>
2. DNCP – Datos de contrataciones, adjudicaciones y contratos. <https://www.contrataciones.gov.py/datos/>
3. 4. Open Contracting Partnership — Contract amendments to increase price https://www.open-contracting.org/wp-content/uploads/2024/12/OCP2024-RedFlagProcurement-1.pdf?utm_source=chatgpt.com
4. OECD. *Anti-Corruption and Integrity Outlook 2026 — Integrity in public procurement*. https://www.oecd.org/en/publications/anti-corruption-and-integrity-outlook-2026_16708b78-en/full-report/component-14.html